

OYUNCU DAVRANIŐI ANALİTİĐİ VE ERKEN TERK (CHURN) TAHMİN SİSTEMİ

30 GÜNLÜK STAJ PROGRAMI

PROBLEM VE HEDEF




- Bu projenin amacı, mobil oyunlarda oyuncu kaybını (churn) önceden tespit eden uçtan uca çalışır bir sistem geliştirmektir.
- Oyuncuların oyunu terk edeceğini önden tahmin edememe problemini çözmek amacıyla; verinin temizlenmesinden model eğitime ve elde edilen tahminlerin etkileşimli bir Streamlit panosunda sunulmasına kadar tüm veri bilimi akışı tek bir mimaride birleştirilmiştir.





YAKLAŞIM VE MİMARİ



Proje bağımlılıklarını izole etmek için sanal ortam (.venv) ve modüler bir dizin yapısı kuruldu. Kodun farklı makinelerde çakışmadan, sorunsuz çalışabilmesi için böyle tercih edilmiştir.

Hem Kaggle verisi hem de kendi oluşturduğum veri seti yüklendi. Kendi veri setimde özgün bir fikir olarak mevsimlerin oyun süreleri üzerindeki etkisini kurguladım.

Veri temizliği yapıp pytest ile test edildi; ardından modeller eğitildi. Karşılaştırma sonucunda daha yüksek doğruluk ve tahmin başarısı sağladığı için canlı sistemde Random Forest modeli tercih edildi.

Eğitilen model joblib ile kaydedilip etkileşimli bir Streamlit panosuna bağlandı. Risk altındaki oyuncular ve temel metrikleri canlı olarak kolayca takip edebilmesi için bu yapı tercih edildi.



CANLI DEMO

Streamlit Panosu

Eğitilen Random Forest modeli, Kaggle ve My Dataset seçenekleriyle etkileşimli bir panoya dönüştürülmüştür:

Genel Bakış: Toplam, aktif ve terk eden oyuncu metrikleri ile veri seti özetlerini sunar.

Risk Altındaki Oyuncular: Churn riski taşıyan oyuncuları listeler, ID araması ve CSV indirme imkanı sağlar.

Model Metrikleri: Model başarı oranlarını (Precision, Recall, F1, Accuracy) ve özellik önem düzeylerini gösterir.

Grafik Analizleri: Terk eden oyuncuların seviye, süre, mevsimsel saat ve yaş dağılımlarını görselleştirir.

Panoya Git





KARŞILAŞILAN ZORLUKLAR VE ÇÖZÜMLER

Karşılaşılan Zorluklar

- Projenin ilk aşamalarında domain bilgisi eksikliği, kullanılan kütüphanelerin yeterince bilinmemesi ve Jupyter Notebook ortamında yaşanan teknik/çalışma sorunları süreçte zorlayıcı oldu. Model eğitimi aşamasında ise, kendi oluşturduğum veri setindeki Churn kurgusunun model tarafından ezberlendiği (overfitting) fark edildi.

Çözümler

- Süreç içinde yapılan araştırmalarla bilgi eksikliği giderildi ve gerekli güncellemeler yapılarak Jupyter Notebook ortamı çalışır hale getirildi. Veri setindeki churn hesaplama mantığı ve kuralları yeniden kurgulanarak modelin ezbere öğrenmesi engellendi; böylece modelin daha gerçekçi ve doğru tahminler yapması sağlandı.

ÖĞRENİLENLER

Teknik Kazanımlar

- Projenin ihtiyaçlarına uygun olarak sıfırdan veri seti kurgulayıp üretebilmek.
- Uçtan uca veri hattı (pipeline) kurabilmek ve içeriğinde veri temizleyebilmek, özellik mühendisliğine uygun metrikler ekleyebilmek, pytest ile test edebilmek.
- Model eğitim sürecini tamamlamak ve tahmin yaptırabilmek gibi teknik kazanımlar kazandırdı.

Teknik Olmayan Kazanımlar

- Her hafta yapılan durum raporları ve haftalık görevlerde olan analiz/değerlendirme raporlarını hazırlamak, düzenli rapor yazma alışkanlığı kazandırdı.
- Her hafta planlı ve düzenli bir çalışma disiplini edinmek; yapılan işleri toplantılarda etkili bir dille ifade etme becerisi kazandırdı.



GELECEK GELİŞTİRMELER

Daha Fazla Zaman Olsaydı?

- Kendi oluşturduğum veri setindeki oyuncu davranış kalıpları üzerinde çalışılarak, veri seti gerçek hayat senaryolarına daha yakın ve daha gerçekçi bir hale getirilebilirdi.
- Sistem sadece "Bu oyuncu oyunu terk edebilir" tahminini yapmakla kalmayıp, riskli görülen oyuncuların oyunda kalmasını sağlayacak (özel teklifler, teşvikler veya yönlendirmeler gibi) aksiyon mekanizmaları panoya eklenebilirdi.

